课程二：机器学习中的回归与分类任务

源自：南京邮电大学计算机学院郭贤杰老师

引言

> 在课程一中，我们已经系统学习了Python的语法体系、数据结构、面向对象机制与常用标准库，并通过5个手写项目锻炼了独立编写代码的能力。本课程在此基础上更进一步，带你走进机器学习，深入理解其中两个最基本也最重要的任务类型：**回归与分类**。
> 课程采用"理论学习 + Python实战"相结合的方式：先建立对机器学习基本概念与一般流程的认识，再分别掌握回归与分类的常用算法及其评估指标，最后借助sklearn在真实数据集上完成完整的实验流程。由于你已经具备扎实的Python基础，本课程的重点不再是"能不能跑通代码"，而是"能不能读懂算法在做什么、能不能正确设计与解读一次实验"。课程结束后的作业将帮助你巩固所学知识并检验学习成果。
> 本次课程的主要内容包括：
>
> 1. 机器学习基本概念与一般流程
> 2. 学习机器学习中的回归任务
> 3. 学习机器学习中的分类任务
> 4. Python实战回归与分类任务
> 5. 完成课程作业

内容一：机器学习基本概念与一般流程

> - 初识机器学习并掌握相关基本概念：机器学习简介、机器学习常见任务、机器学习任务一般流程、梯度下降法原理 等
> - 环境准备：在课程一已配置好的Python环境中安装实验所需的第三方包（ `pip install scikit-learn pandas matplotlib` ，若下载缓慢请配置国内镜像源）
> - **学习要点**：分清监督学习与无监督学习；理解样本、特征、标签、训练集与测试集这些基本术语；掌握机器学习任务的一般流程（数据准备 → 特征处理 → 模型训练 → 模型评估 → 结果分析）；理解梯度下降为什么能让模型"学"到参数，以及学习率过大或过小分别会带来什么后果

内容二：学习机器学习中的回归任务

- 了解回归任务的基本概念：预测目标为**连续值**（如房价、温度、销量），细节可直接咨询Gemini、DeepSeek、ChatGPT等大语言模型
- 熟悉用于**回归任务**的常用算法：线性回归、多项式回归、Lasso回归、决策树回归等（每种算法的细节可以直接咨询Claude（课题组内部会用使用链接）、Gemini、DeepSeek、ChatGPT等大语言模型）
- 熟悉回归任务的评估指标：均方误差（MSE, Mean Squared Error）、均方根误差（RMSE, Root Mean Squared Error）、平均绝对误差（MAE, Mean Absolute Error）等（参考视频）
- **学习要点**：理解Lasso（L1）与Ridge（L2）正则化在抑制过拟合上的不同作用；思考RMSE与MAE对异常值的敏感程度为何不同，以及在什么场景下应优先选用哪一个

内容三：学习机器学习中的分类任务

- 了解分类任务的基本概念：预测目标为**离散类别**（如是否患病、图片属于哪个数字），细节可直接咨询Gemini、DeepSeek、ChatGPT等大语言模型
- 熟悉用于**分类任务**的常用算法：逻辑回归、决策树分类、支持向量机、K近邻算法等（每种算法的细节可以直接咨询Gemini、DeepSeek、ChatGPT等大语言模型）
- 熟悉分类任务的评估指标：准确率（Accuracy）、精确率（Precision）、召回率（Recall）、F1 分数等（参考视频）
- **学习要点**：注意"逻辑回归"虽名为回归，实为分类算法；理解混淆矩阵与四种评估指标之间的换算关系；思考在类别极不平衡的数据集上，为什么仅看Accuracy会产生误导，而F1分数更有参考价值

内容四：Python实战回归与分类任务

回归任务实战

- [x] 线性回归实战之糖尿病数据预测
- [x] 决策树回归实战之鸢尾花数据预测

分类任务实战

- [x] 逻辑回归实战之手写数字分类
- [x] K近邻算法实战之预测电影类型
- [x] K近邻算法实战之预测年收入是否大于50K

实战建议：不要只跟着视频复制代码。请在跟做一遍之后关闭视频，用课程一学到的模块化思路自己重写一遍：把数据加载、模型训练、指标计算分别封装成函数，主程序只负责调度。这套结构将直接复用到下面的课程作业中。

内容五：完成课程作业

- ☐ 从UCI机器学习数据库 中任意选择**六个用于回归任务的数据集**，再从sklearn包（一种常用的Python机器学习包，详细用法可咨询Claude（课题组内部会用使用链接）、Gemini 、DeepSeek 、ChatGPT 等大语言模型）中任意选择**三个用于回归任务的算法**，在上述六个数据集上分别运行5折交叉验证 ，并将实验结果（***仅展示RMSE指标***）用下述表格展示（单元格中"A"表示5折验证结果的均值，"B"表示5折验证结果的标准差）

数据集名称＼ 算法名称	回归算法1	回归算法2	回归算法3
数据集1	A±B	A±B	A±B
数据集2	A±B	A±B	A±B
数据集3	A±B	A±B	A±B
数据集4	A±B	A±B	A±B
数据集5	A±B	A±B	A±B
数据集6	A±B	A±B	A±B

- ☐ 从UCI机器学习数据库中任意选择**六个用于分类任务的数据集**，再从sklearn包中任意选择**三个用于分类任务的算法**，在上述六个数据集上分别运行5折交叉验证，并将实验结果（***需要展示Accuracy与F1分数两种指标，分别用两张表格呈现***）用下述表格展示（单元格中"A"表示5折验证结果的均值，"B"表示5折验证结果的标准差）

数据集名称 \ 算法名称	分类算法1	分类算法2	分类算法3
数据集1	A±B	A±B	A±B
数据集2	A±B	A±B	A±B
数据集3	A±B	A±B	A±B
数据集4	A±B	A±B	A±B
数据集5	A±B	A±B	A±B
数据集6	A±B	A±B	A±B

- ☐ **代码规范要求（承接课程一）**：实验代码需按模块划分（如 `data_loader.py` 、 `experiment.py` 、 `main.py` ），对数据缺失、类型异常等情况用 `try/except` 妥善处理，并保证设置随机种子后实验结果可复现

课程作业要求：

请在**课程二截止日期前**（拿到作业后的2-3周内完成即可）将实验结果表格（用Excel展示）以及可复现实验结果的Python项目代码一起打包压缩，发送至邮箱：xianjieguo@njupt.edu.cn，压缩包命名方式为：**"科研入门培训+课程二+姓名"**。